Высшая Школа Экономики

Исследовательский проект

Оптимальные способы моделирования сезонности во временных рядах

Бунин Иван

Пунов Дмитрий

10 марта 2026

г. Москва

Введение

Сезонность – это повторяющиеся, предсказуемые колебания данных с фиксированной периодичностью. Её наличие в данных оказывает прямое влияние на эффективность моделей прогнозирования временных рядов. Необходимо правильно обрабатывать такой эффект. Кроме классических методов возможно моделировать сезонность разными способами, опираясь на информацию о структуре ряда, и о его поведении в прошлом. В данном исследовании рассмотрены методы прогнозирования, с использованием моделей градиентного бустинга на различных наборах параметров, характеризующих временной ряд. Также приведено сравнение с бейзланами классических моделей: наивного прогноза, наивного сезонного прогноза, Auto.ETS и Auto.Theta.

Распределение ролей

Бунин Иван – отбор фичей, обучение глобальных CatBoost моделей, автоматизация экспериментов в исследовании

Пунов Дмитрий – подготовка и предобработка данных, реализация бейзлайнов, подготовка отчёта

Общие задачи – анализ результатов, подведение итогов исследования

Методика измерений

Для проведения исследования был выбран датасет M4 содержащий ряды с сезонностью с недельным частотность. В качестве рядов для экспериментов были выбраны ряды с номерами 'W234', 'W247', 'W7', 'W27', 'W30', 'W31', 'W237', 'W6', 'W56', 'W243'. В данных рядах наиболее четко видна сезонность при построении автокорреляционной и частичной автокорреляционной функций. Графики ACF и PACF для рядов приведены на рисунках 1–10.

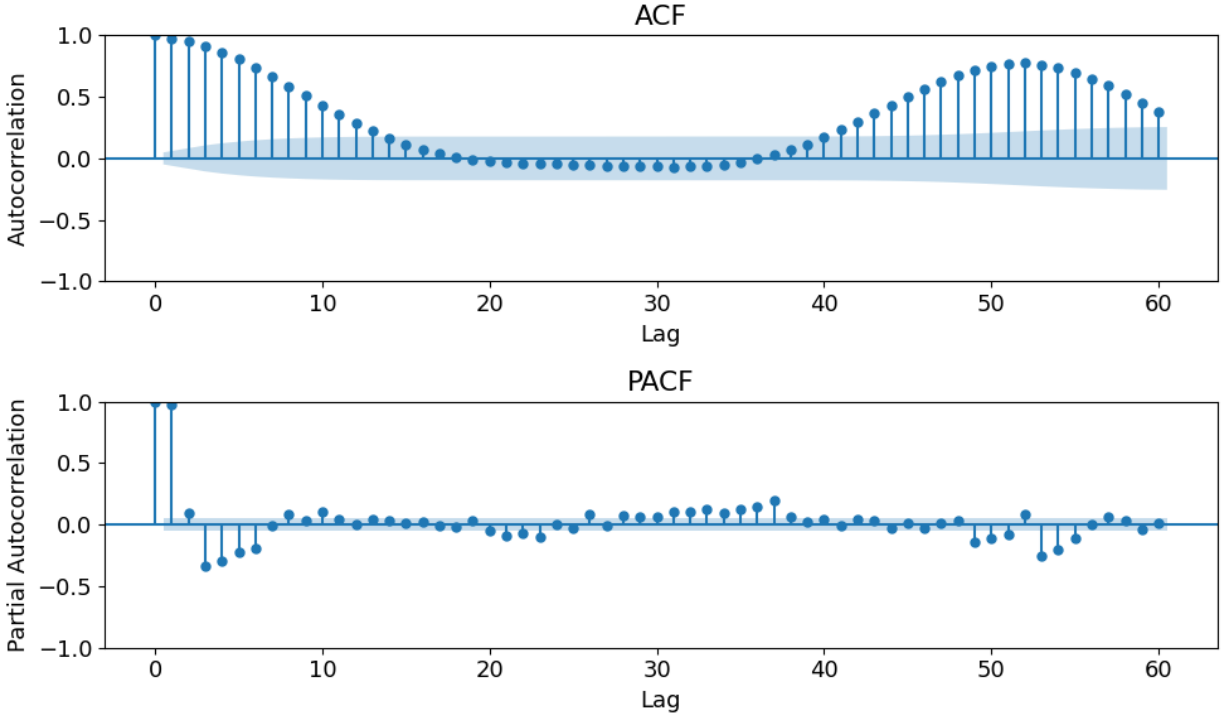

Рисунки 1–3. Графики ACF и PACF для исследуемых временных рядов.

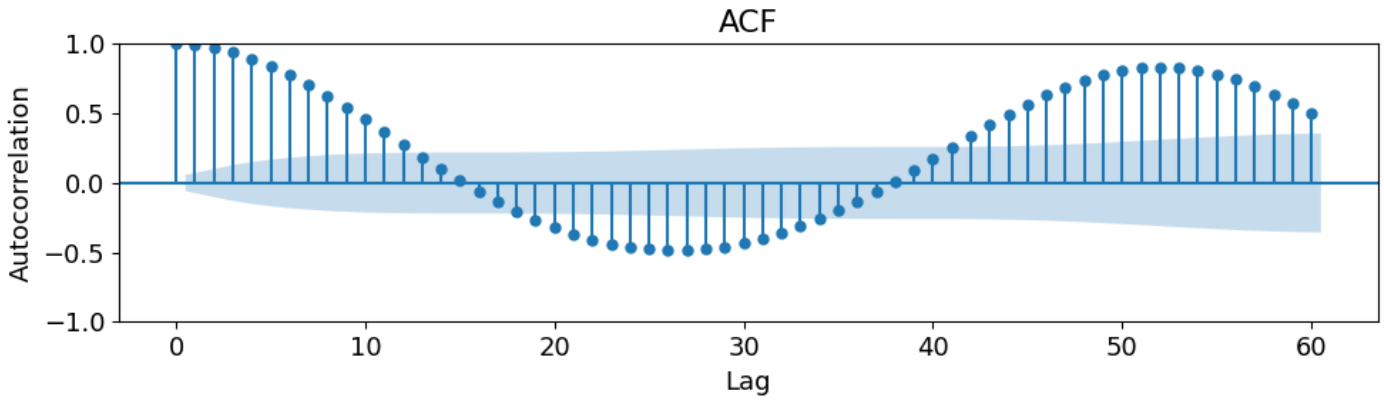

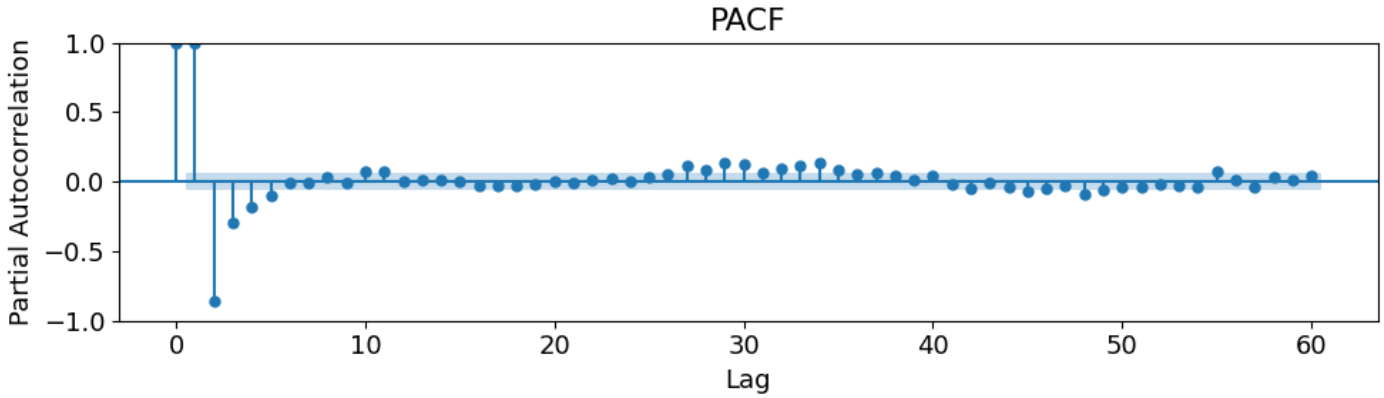

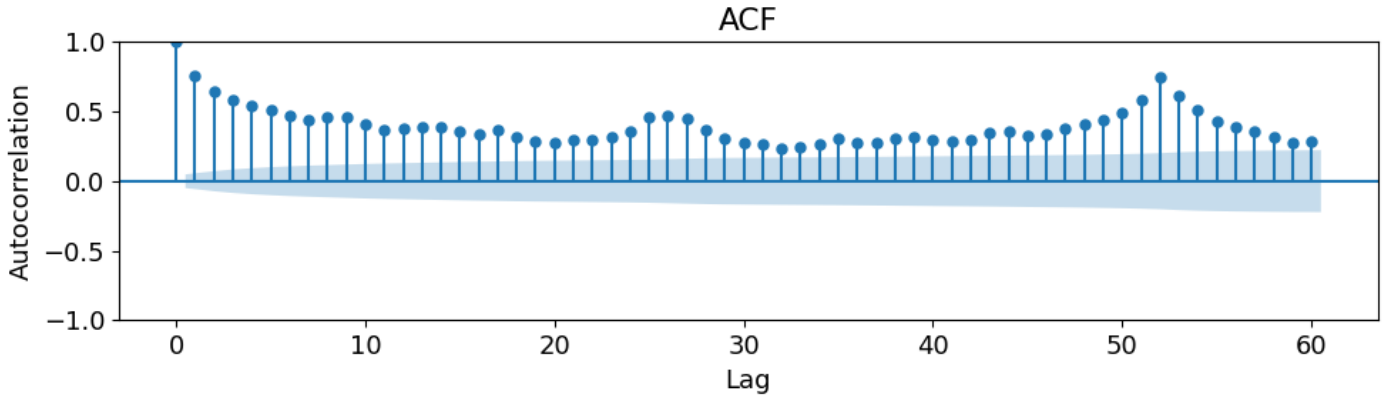

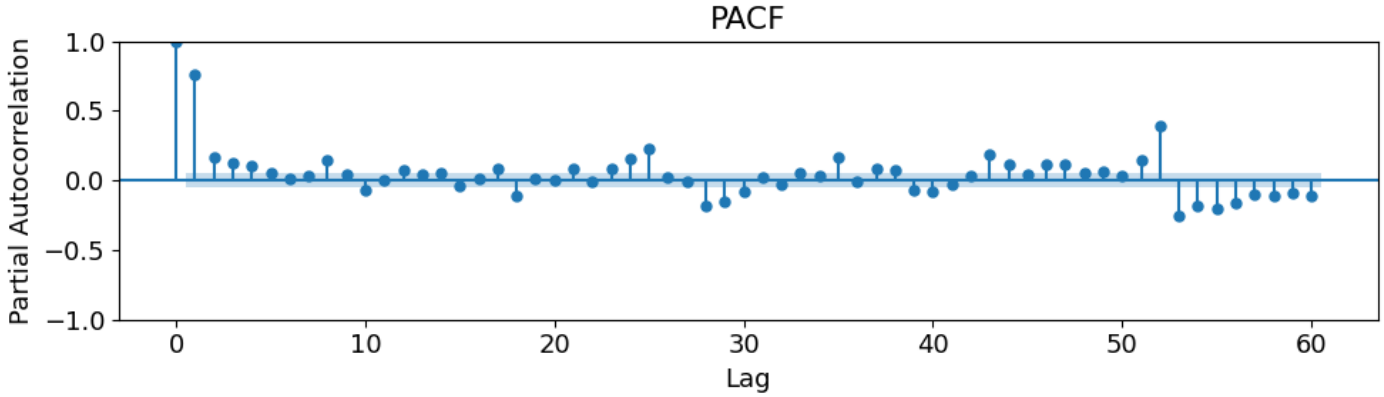

В качестве основных метрик, с помощью которых будет проводиться оценка эффективности каждого метода, были выбраны следующие:

- *SMAPE* – основная метрика отражающее качество модели, позволяет оценивать ряды с разными уровнями (инвариантность). Симметрична; выражается в процентах, что упрощает задачу сравнения качества каждого из методов; не чувствительна к выбросам. Данная метрика является основной для датасета M4.

Далее были выбраны основные модели в качестве бейзлайнов:

- *Naive* – горизонт прогнозирования, есть константное значение, последнее для данного ряда.
- *SeasonalNaive* - заполняет горизонт прогнозирования значениями из прошлого сезона (является лучшим бейзлайном и необходим для сравнения в метрике MASE).
- *AutoTheta* – автоматический вариант Theta метода.
- *AutoETS* – автоматический вариант экспоненциального сглаживания.

Основным объектом исследования является возможность прогнозирования временного ряда посредством применения информации о сезонности в прошлом. Далее описаны основные наборы фичей, проверяемых в данном исследовании:

- *лаги* – информация о предыдущем состоянии ряда (не учитывает и не заглядывает в сезонность)
- *лаги и сезонные лаги* – к информации о состоянии ряда в прошлом, также добавляется информация о поведении ряда в предыдущем сезоне
- *лаги и календарные признаки* – к информации о состоянии ряда в прошлом, также добавляется информация о календарных признаках (необязательно связанных с сезонностью
- *лаги и фурье-признаки* - к информации о состоянии ряда в прошлом, также добавляется информация о фурье характеристиках ряда (представление сезонности в ряде периодическими функциями)
- *комбинированные признаки* – комбинации признаков приведенных ранее.

В качестве глобальной модели была выбрана Recursive-MIMO модель позволяющая делать прогнозы на всех рядах одновременно. К информации о лагах добавлялась информация об описанных ранее признаков и модель обучалась на всех рядах

Результаты экспериментов

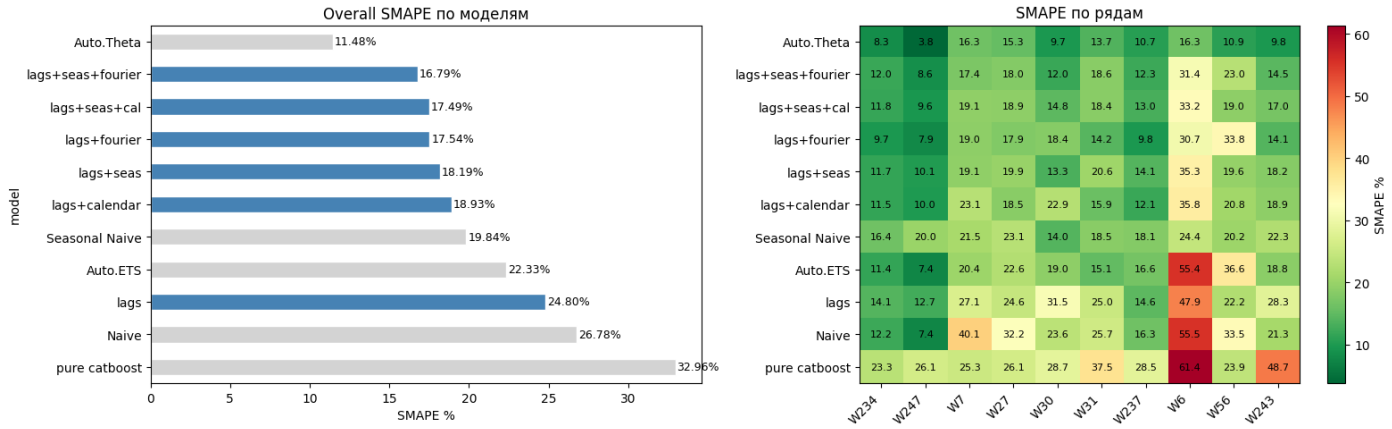

Рисунок 11. Метрика SMAPE для каждого из предложенных бейзлайнов и наборов фичей

Из оценки предложенных методов прогнозирования видно, что CatBoost обученный только на лагах показывает результат сравнимый с наивным прогнозом. Добавление дополнительных признаков позволяет значительно улучшить предсказание. Таким образом CatBoost обученный

на информации о лагах, сезонных лагах и фурье характеристиках ряда (далее LSF) показывает прирост по метрике SMAPE на 8% в сравнении с наивным прогнозом.

Для дальнейшего анализа необходимо ввести определение силы сезонности во временном ряде. Воспользовавшись разложением ряда STL (Seasonal-Trend decomposition) разобъем ряд на три компоненты:

$$y_t = Trend_t + Seasonal_t + Remainder_t$$

Определим метрику силы сезонности, как:

$$F_S = \max\left(0, 1 - \frac{\mathrm{Var(Remainder)}}{\mathrm{Var(Seasonal + Remainder)}}\right)$$

Если дисперсия сезонной компоненты значительно перевешивает дисперсию остатков, значение данной величины будет стремиться к 1, то есть ряд содержит сильную сезонность.

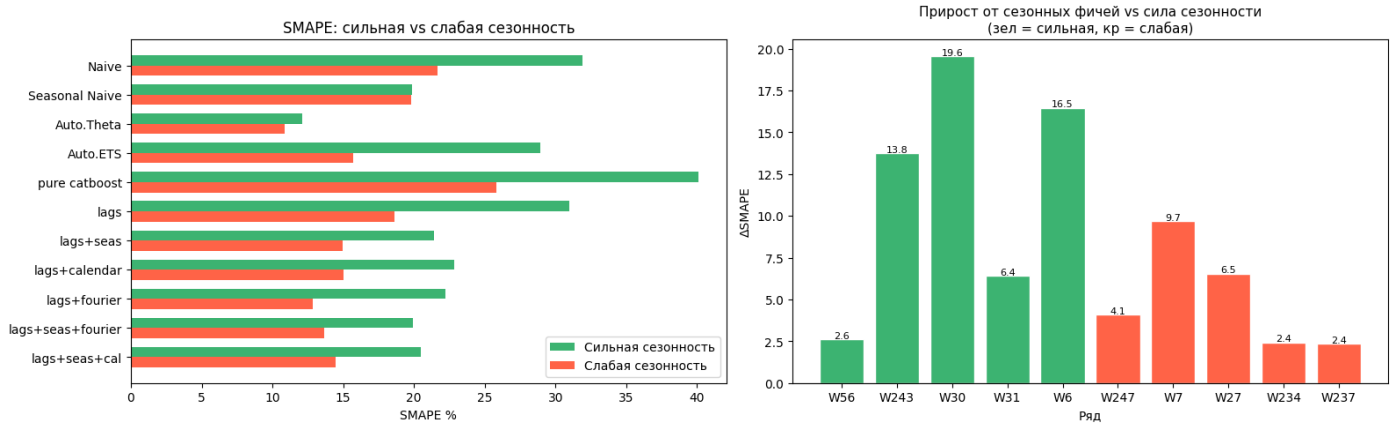

Рисунок 12. Метрика SMAPE для каждого из предложенных бейзлайнов и наборов фичей в зависимости от силы сезонности в временных рядах

При введении дополнительной метрики определяющей силу сезонности, видно что метод LSF позволяет хорошо строить прогнозы, однако все еще проигрывает Auto.Theta. На правом рисунке отражен прирост метрики SMAPE от добавления сезонных фичей, для каждого из рядов содержащих различные уровни сезонности (больше медианного значения и меньше медианного значения по всем рядам).

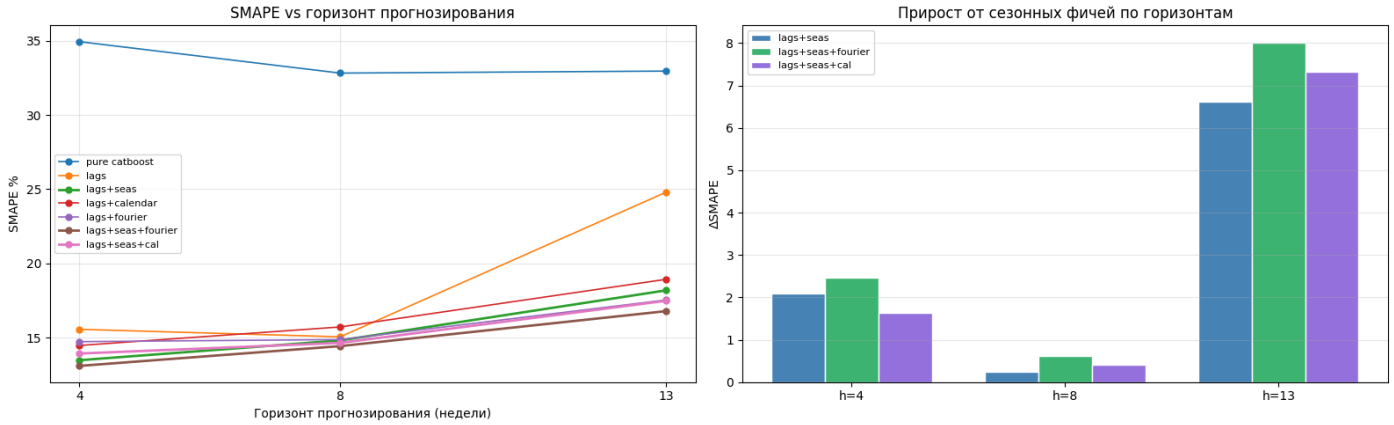

Рисунок 13. Метрика SMAPE для разных горизонтов прогнозирования. Вклад сезонных фичей в качество прогнозирования на временных рядах

Аналогичное сравнение было проведено для разных горизонтов прогнозирования от 4 до 13 доступных в датасете наблюдений. Можно заметить что для горизонта прогнозирования эффект от добавления сезонных фичей значительно ниже, чем на более длинных и коротких горизонтах. Данное явление может быть объяснено структурой самих рядов (возможно лаги и сезон попадают на период, в котором сезонный эффект не так заметен).

В таблице ниже приведены сравнительные результаты для каждого из рассмотренных в работе методов.

Модель	SMAPE	W234	W247	W7	W27	W30	W31	W237	W6	W56	W243
Auto.Theta	11,48	8,32	3,77	16,27	15,34	9,67	13,73	10,67	16,26	10,93	9,81
LSF	16,79	12,03	8,59	17,41	18,01	11,97	18,62	12,26	31,44	23,04	14,53
LSC	17,49	11,76	9,6	19,14	18,92	14,76	18,43	13,02	33,24	18,99	17,01
LF	17,54	9,71	7,94	18,96	17,87	18,37	14,25	9,77	30,69	33,81	14,05
LS	18,19	11,65	10,1	19,15	19,95	13,29	20,56	14,05	35,26	19,64	18,23
LC	18,93	11,49	10,03	23,06	18,49	22,89	15,89	12,07	35,75	20,79	18,86
SN	19,84	16,35	20,01	21,46	23,11	13,98	18,53	18,06	24,39	20,25	22,31
Auto.ETS	22,33	11,43	7,42	20,4	22,61	18,97	15,05	16,65	55,38	36,6	18,75
Lags	24,8	14,08	12,68	27,1	24,56	31,53	25,04	14,61	47,91	22,25	28,29
Naive	26,78	12,25	7,42	40,13	32,17	23,58	25,69	16,3	55,52	33,46	21,27
Catboost	32,96	23,26	26,12	25,26	26,07	28,74	37,55	28,52	61,41	23,92	48,73

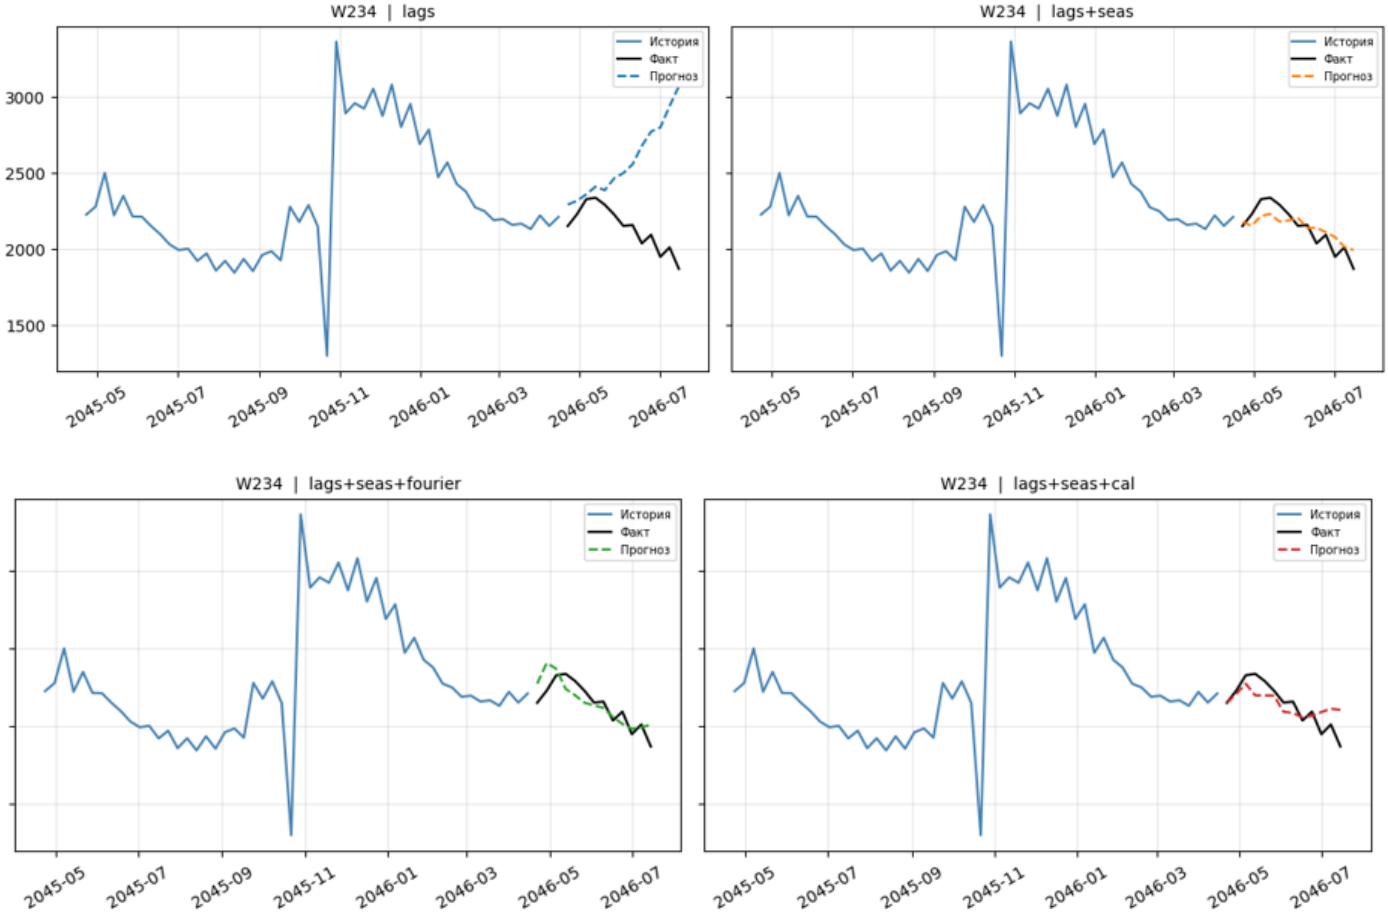

Рисунок 14. Пример сравнения прогноза и фактических данных для различных наборов фичей: лаги; лаги и сезонность; лаги, сезонность и фурье-характеристики; лаги, сезонность и календарные признаки

Выводы

Были рассмотрены различные модели, с использованием сезонных фичей, таких как лаги сезонные лаги, календарные признаки, Фурье-характеристики и их комбинации.

Добавление лаговых фичей позволяет значительно увеличить качество прогноза. Так, добавление Фурье-характеристик и сезонных лагов, позволяет добиться хороших результатов как на рядах содержащих сильную, так и слабую сезонности. Предложенные методы показывают себя лучше на коротких горизонтах прогнозирования.

Также стоит отметить существование зависимости эффект от добавления сезонных фичей и горизонта прогнозирования. Так на более длинных горизонтах прогнозирования этот эффект увеличивается, то есть на длинных горизонтах эффект становится сильнее.

Таким образом самым оптимальным набором лаговых фичей, будет являться тот, который на средних горизонтах прогнозирования сможет вносить достаточное количество информации о сезонности. То есть необходимо найти баланс между качеством прогноза, и возможностью прогнозировать на более длительные горизонты.

Однако по результатам исследования предложенные методы не превзошли бейзлайн модели Auto.Theta. Необходимо детально подходить к отбору параметров определяющих фичи например выбирать количество лагов используемых для подсчёта конкретной фичи.